



**TECHNIQUES  
DE L'INGÉNIEUR**

Réf. : **R1815 V1**

Date de publication :  
**10 juin 2021**

Date de dernière validation :  
**24 juin 2021**

# Reconnaissance d'activités à partir des données d'un accéléromètre

Cet article est issu de : **Mesures - Analyses | Mesures mécaniques et dimensionnelles**

par **Romain AUBER, Mathieu POULIQUEN,  
Éric PIGEON**

## Mots-clés

Reconnaissance d'activités |  
Données accélérométriques

**Résumé** La reconnaissance d'activités à partir de données issues de capteurs a de nombreuses applications telles que le suivi postopératoire de patients en médecine ambulatoire ou le suivi des activités physiques quotidiennes de personnes âgées. Il est choisi ici de ne considérer que les données fournies par un accéléromètre. L'accéléromètre est en effet un capteur permettant une récolte aisée de données sans être dépendant de l'environnement de l'utilisateur, ceci de par sa disponibilité sur des smartphones ou dispositifs dédiés. Le but de cet article est de faire une revue des solutions proposées dans la littérature pour la reconnaissance d'activités sur la base de données accélérométriques.

## Keywords

Activity Recognition |  
Accelerometer Data

**Abstract** Data based activity recognition has many applications such as postoperative monitoring of ambulatory medicine patients or monitoring of the daily physical activities of elderly people. In this paper it is chosen to consider only the data supplied by an accelerometer. Indeed the accelerometer is a sensor allowing an easy data collection without being dependent on the user's environment, this due to its availability on smartphones or dedicated devices. The aim of this paper is to review the solutions proposed in the literature for the activity recognition on the basis of accelerometric data.

## Pour toute question :

Service Relation clientèle  
Techniques de l'Ingénieur  
Immeuble Pleyad 1  
39, boulevard Ornano  
93288 Saint-Denis Cedex

**Par mail :**  
infos.clients@teching.com  
**Par téléphone :**  
00 33 (0)1 53 35 20 20

Document téléchargé le : **13/04/2023**

Pour le compte : **7200045224 - universite de strasbourg // 130.79.14.140**

© Techniques de l'Ingénieur | tous droits réservés

# Reconnaissance d'activités à partir des données d'un accéléromètre

par **Romain AUBER**

*Docteur ingénieur  
Bodycap, France*

**Mathieu POULIQUEN**

*Maître de conférences  
Université de Caen Normandie, Caen, France*

et **Éric PIGEON**

*Maître de conférences  
Université de Caen Normandie, Caen, France*

<b>1. Méthodologie générale pour la reconnaissance d'activités .....</b>	<b>R 1 815 - 2</b>
<b>2. Acquisition des données .....</b>	<b>— 2</b>
2.1 Données accélérométriques.....	— 2
2.2 Fréquence .....	— 4
2.3 Placement des capteurs.....	— 4
<b>3. Prétraitement des données .....</b>	<b>— 5</b>
3.1 Filtrage .....	— 5
3.2 Fenêtrage.....	— 5
<b>4. Extraction et sélection de paramètres de classification.....</b>	<b>— 6</b>
4.1 Liste des paramètres usuels.....	— 6
4.2 Sélection des paramètres.....	— 8
4.3 Normalisation des paramètres .....	— 9
<b>5. Classification .....</b>	<b>— 9</b>
5.1 Classification par les plus proches voisins .....	— 10
5.2 Classification naïve bayésienne.....	— 10
5.3 Classification par séparateur à vaste marge (SVM) .....	— 10
5.4 Classification par réseau de neurones .....	— 11
5.5 Classification par analyse discriminante.....	— 11
5.6 Classification par arbre de décision .....	— 11
5.7 Classification par les forêts aléatoires.....	— 12
5.8 Combinaison d'algorithmes de classification.....	— 12
<b>6. Validation .....</b>	<b>— 12</b>
6.1 Données de validation .....	— 12
6.2 Indicateurs de performance .....	— 13
<b>7. Conclusion.....</b>	<b>— 13</b>
<b>8. Glossaire .....</b>	<b>— 14</b>
<b>Pour en savoir plus .....</b>	<b>Doc. R 1 815</b>

**L**a reconnaissance d'activités est un problème particulièrement saillant tant de par ses applications pratiques multiples que par les problématiques de recherche qu'elle révèle. Parmi les applications pratiques, nous pouvons citer par exemple le suivi postopératoire en médecine ambulatoire, la détection d'anomalies liées à la santé, la prévention des chutes ou encore, à des fins plus légères, le suivi des activités physiques quotidiennes via une estimation

de la dépense calorique ou le suivi des activités sportives (durée d'une course, distance parcourue, etc.).

Il existe plusieurs solutions pour appréhender l'activité d'une personne à partir de capteurs. Une première possibilité consiste à faire de la reconnaissance d'activités à partir d'images ou de vidéos, cependant l'utilisation de données visuelles a deux défauts majeurs : d'une part, la personne doit rester dans le champ de la caméra, d'autre part, certains utilisateurs peuvent être réticents à être constamment sous l'œil d'une caméra dans leur vie privée. Une autre possibilité est donc d'utiliser des capteurs portés par l'utilisateur. À ce titre, en raison de sa démocratisation, de sa discrétion et de sa puissance de calcul, le smartphone peut être utilisé pour collecter des données sur les individus et ces données peuvent être utilisées pour de la reconnaissance d'activités. La plupart des smartphones contiennent en effet de nombreux capteurs tels que des accéléromètres, des gyroscopes, des magnétomètres, etc. Outre le smartphone, des dispositifs peuvent être spécifiquement développés pour la reconnaissance d'activités. Il existe par exemple des dispositifs portables intégrant directement un accéléromètre, un gyroscope et un magnétomètre. Dans d'autres cas, outre les différentes mesures issues des capteurs précédents, des signaux physiologiques, tels que la fréquence cardiaque, la fréquence respiratoire et la saturation en oxygène, peuvent aussi être utilisés. Dans cet article, nous supposons prendre uniquement en compte les données fournies par un accéléromètre. L'accéléromètre est en effet le capteur porté le plus utilisé dans la reconnaissance d'activités. L'utilisation de ce capteur permet de pouvoir récolter des données de n'importe quel endroit et il permet de ne plus être dépendant de l'environnement de l'utilisateur.

Dans cet article nous nous intéressons ainsi à la procédure permettant la reconnaissance d'activités sur la base de données accélérométriques. Cette procédure consiste en l'enchaînement de différentes étapes dont le résultat final est conditionné par des choix de l'utilisateur à chacune des étapes. Il s'agit ainsi dans cet article de faire un état des lieux sur cette procédure en détaillant les éléments technologiques de chacune des étapes et les choix usuels en reconnaissance d'activités.

## 1. Méthodologie générale pour la reconnaissance d'activités

Comme décrit dans [1], [2] et [3], la reconnaissance d'activités suit les étapes énoncées dans le standard CRISP-DM (*Cross Industry Standard Process for Data Mining*). Ce standard établit un modèle de traitement de données. En termes de reconnaissance d'activités, ce standard se traduit par la procédure représentée sur la figure 1 et correspondant aux étapes suivantes :

- la première étape est la collecte d'un grand nombre de données des différentes activités ciblées. Les types de données utilisés dans la reconnaissance d'activités sont décrits dans la section 2 ;
- ensuite, un prétraitement des données est effectué sur les données. Ce prétraitement consiste en un filtrage et un fenêtrage des données, fenêtrage consistant à découper le signal en différentes fenêtres. Le prétraitement des données est décrit dans la section 3 ;
- par la suite, différents paramètres sont calculés sur chaque fenêtre pour être ensuite utilisés par des algorithmes de classification. Dans la section 4 sont exposés les paramètres les plus souvent utilisés dans la littérature ;
- les paramètres calculés à l'étape précédente sont utilisés au sein d'un classifieur, algorithme dédié à la reconnaissance d'activités proprement dite. La section 5 est dédiée aux algorithmes de classification les plus utilisés pour la reconnaissance d'activités ;

– pour finir, les outils pour l'évaluation, et donc la validation ou non, de l'ensemble de la procédure sont présentés dans la section 6.

Dans la suite de cet article nous détaillons le contenu de chacune de ces étapes en précisant les choix usuels pour l'utilisateur.

## 2. Acquisition des données

### 2.1 Données accélérométriques

Les données brutes sont en général collectées par un accéléromètre se trouvant soit sur un **smartphone**, soit sur un objet connecté dédié. L'avantage d'utiliser un smartphone est de collecter les données d'un utilisateur de manière discrète à l'aide d'une application, sans ajout d'un matériel supplémentaire. À noter cependant que l'utilisateur risque de modifier la position de son smartphone assez souvent ; l'utilisation d'une **plateforme dédiée** a pour avantage de pouvoir positionner et fixer le capteur à un endroit précis du corps. Le type d'équipement usuellement utilisé dans les études est décrit dans le tableau 1.

Dans le cas de l'utilisation d'objets connectés, un seul ou plusieurs accéléromètres peuvent être utilisés. L'avantage d'utiliser plusieurs capteurs est d'avoir plus d'informations si les capteurs sont placés à différents endroits. Dans [29], sept capteurs sont placés à des endroits différents du corps et 63 combinaisons pos-

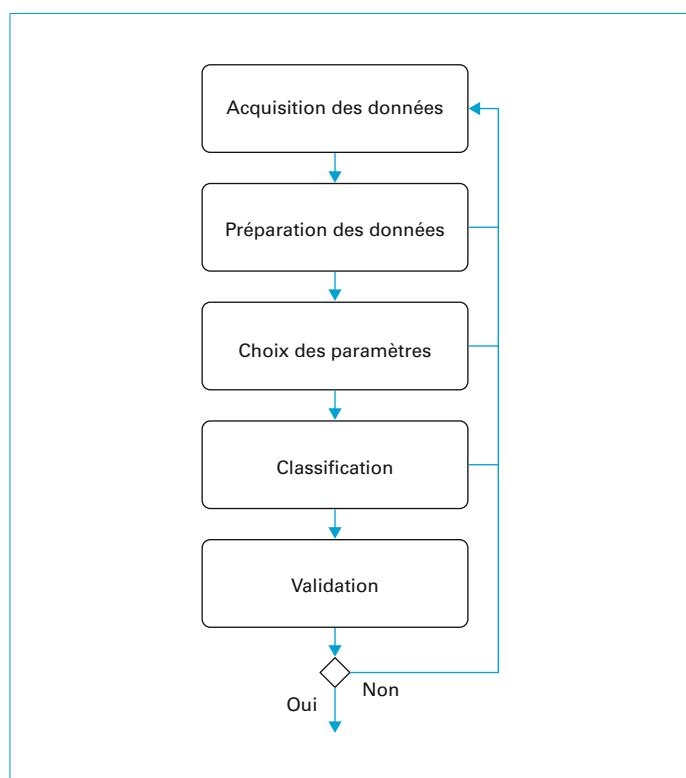


Figure 1 – Structure de la procédure de reconnaissance d'activités

Tableau 1 – Type d'équipement utilisé pour la collecte de données

Type d'équipement	Références
Smartphone	[4] [5] [6] [7] [8] [9] [10] [11] [12] [13] [14]
Plateforme dédiée	[15] [16] [17] [18] [19] [20] [21] [22] [23] [24] [25] [26] [27] [28]

sibles entre ces capteurs sont étudiées. Dans cette étude, avec un seul capteur, le taux de reconnaissance d'activités est de 96,60 % en moyenne. Le meilleur résultat est obtenu avec la combinaison des données de trois capteurs, combinaison permettant un taux de reconnaissance de 97,66 % en moyenne.

L'accéléromètre fournit trois données différentes :

- $a_x$  qui représente l'accélération suivant l'axe  $x$  ;
- $a_y$  qui représente l'accélération suivant l'axe  $y$  ;
- $a_z$  qui représente l'accélération suivant l'axe  $z$ .

Dans le cas où le capteur a une position et une orientation fixes, les données de chaque axe peuvent être utilisées directement pour faire de la reconnaissance d'activités. Si le capteur n'a pas de position et d'orientation fixes, les valeurs des accélérations  $a_x$ ,  $a_y$  et  $a_z$  sont différentes en fonction de l'orientation du capteur, il est alors possible d'utiliser la norme du vecteur accélération définie par :

$$a_n = \sqrt{a_x^2 + a_y^2 + a_z^2} \quad (1)$$

L'avantage de travailler avec la norme est que le capteur n'a pas besoin d'avoir une position fixe. En pratique c'est un cas qu'on rencontre fréquemment. Par exemple, si l'accéléromètre d'un smartphone est utilisé, le téléphone est souvent situé dans la poche, son orientation est donc non déterminée. Dans ce cas, il est préférable d'utiliser la norme plutôt que directement l'accélération suivant les axes de l'accéléromètre. Cependant, l'utilisation de la norme a pour défaut de conduire à une perte d'informations, informations qui peuvent être déterminantes dans la reconnaissance d'activités. Une solution pour pouvoir quand même utiliser les valeurs des axes dans le cas où le capteur n'est pas fixe est de déterminer l'**orientation du capteur**. Si l'orientation est connue, un changement de repère permet d'utiliser l'accélération suivant les axes. Une méthode simple est de calculer l'orientation du capteur à l'aide de l'accélération terrestre, mais cette méthode requiert que la composante dynamique soit filtrée. Une autre solution est d'utiliser d'**autres capteurs** comme un magnétomètre ou un gyroscope. Par exemple, une méthode est proposée dans [30] afin d'obtenir l'accélération d'un capteur suivant trois axes indépendamment de son orientation et à l'aide d'un magnétomètre.

L'information d'accélération  $a_i$  peut être décomposée en une composante statique induite par la gravité  $a_{ig}$  et une composante dynamique induite par les mouvements de l'utilisateur  $a_{id}$  :

$$a_i = a_{ig} + a_{id} \quad (2)$$

où  $a_i$  peut être  $a_x$ ,  $a_y$ ,  $a_z$  ou  $a_n$ .

La **composante statique** est utilisée en général pour déterminer l'**orientation**, la **partie dynamique** est utilisée pour déterminer les **mouvements** de l'utilisateur. Un seul signal ou l'ensemble des signaux peut être utilisé comme entrée pour la reconnaissance d'activités. Par exemple, l'accélération, la norme, la composante statique et la composante dynamique sont utilisées pour faire de la reconnaissance d'activités dans [31].

Dans le cas où le capteur a une orientation fixe, il est possible de calculer les angles de rotation à l'aide des accélérations des trois axes de la manière suivante :

$$lacet = \text{atan} \left( \frac{a_z}{\sqrt{a_x^2 + a_y^2}} \right) \quad (3)$$

$$tangage = \text{atan} \left( \frac{a_y}{\sqrt{a_x^2 + a_z^2}} \right) \quad (4)$$

$$roulis = \text{atan} \left( \frac{a_x}{\sqrt{a_y^2 + a_z^2}} \right) \quad (5)$$

L'**angle** donne des informations supplémentaires, il permet notamment de déterminer si la personne est allongée ou debout. Les angles de rotation sont utilisés pour faire de la reconnaissance d'activités dans [16], [9], [24], [23] et [10].

Si le capteur peut tourner seulement sur un axe, il est possible d'utiliser les normes calculées sur un plan comme suit :

$$a_{xy} = \sqrt{a_x^2 + a_y^2} \quad (6)$$

$$a_{yz} = \sqrt{a_y^2 + a_z^2} \quad (7)$$

$$a_{xz} = \sqrt{a_x^2 + a_z^2} \quad (8)$$

La norme  $a_{xz}$  est par exemple utilisée dans [18]. Cette norme est utilisée en raison de l'emplacement particulier du capteur : l'accéléromètre est situé sur la ceinture de l'utilisateur. Le capteur peut tourner librement autour de la taille de l'utilisateur, mais l'axe  $y$  reste parallèle au tronc.

## 2.2 Fréquence

La fréquence d'échantillonnage est un paramètre important qui aura un impact sur le temps de calcul et la qualité de la reconnaissance d'activités. Une fréquence d'échantillonnage élevée va permettre de gagner en précision, mais va nécessiter un temps de calcul plus important. La fréquence d'échantillonnage doit aussi être choisie en fonction de la fréquence des mouvements à reconnaître. D'après [32], une fréquence d'échantillonnage de 20 Hz est suffisante pour pouvoir capter les mouvements quotidiens d'une personne. Dans [33], il est montré que la fréquence des activités est comprise entre 10 Hz et 20 Hz et la majeure partie de l'énergie du signal se situe en dessous de 3 Hz. Le tableau 2 liste différentes fréquences d'échantillonnage utilisées dans la littérature. La fréquence d'échantillonnage de l'accéléromètre est souvent comprise entre **10 Hz et 100 Hz**.

## 2.3 Placement des capteurs

Le placement des capteurs est une composante importante à prendre en compte dans la reconnaissance d'activités. Il n'existe pas aujourd'hui de consensus sur un placement optimal et plusieurs positionnements sont proposés dans la littérature. Dans le cas d'un objet connecté dédié, le positionnement du capteur est souvent motivé par la **nature de l'activité suivie**. Une revue des différents placements du capteur est présentée dans le tableau 3.

En général, la position du capteur n'est pas fixe pour les smartphones et peut varier selon l'activité de l'utilisateur. Par exemple, quatre types de pose du smartphone sont prises en compte dans

Tableau 3 – Placement du capteur	
Positionnement	Références
Poignet	[4] [29] [16] [17] [7] [26] [34] [13] [27]
Cheville	[17] [25]
Bras	[4] [16] [17] [34]
Cuisse	[29] [17] [34]
Taille	[4] [29] [16] [17] [18] [20] [21] [9] [10] [34] [11] [25] [37] [28]
Torse	[4] [31] [29] [17] [19] [22] [23] [24] [34]
Dos	[29] [17]
Genou	[4] [16] [36] [25]
Tête	[4] [35] [34]
Pied	[4] [29] [16]

[14] : le smartphone dans la poche, le smartphone à côté de la tête durant un appel, le smartphone qui suit le mouvement de la main durant un mouvement comme la marche et le smartphone dans la main, devant l'utilisateur, durant son utilisation. Dans certains cas, le smartphone doit avoir un emplacement précis. Par exemple, le smartphone doit être positionné au niveau de la taille à l'aide d'une ceinture dans [11] et le smartphone est positionné au niveau du dos dans [35].

Des études comparatives proposent des études de l'impact du positionnement du capteur. Ainsi, dans [4] une étude est faite sur le meilleur positionnement pour suivre les activités de la vie quotidienne. Pour déterminer la meilleure position, des capteurs comportant un accéléromètre sont placés sur sept parties différentes du corps (pied, genou, taille, torse, bras, poignet et tête) sur neuf personnes différentes. Ensuite, un ensemble de paramètres est calculé pour chaque position. Des paramètres sont ensuite sélectionnés pour être utilisés pour faire de la reconnaissance d'activités avec deux algorithmes de classification. Les résultats de cette étude montrent que les paramètres qui permettent de mieux discriminer les mouvements varient selon le placement du capteur. La qualité de la classification varie aussi en fonction du placement du capteur. Par exemple, les meilleurs résultats pour la classification de la marche ont été observés avec un capteur positionné au niveau de la poitrine ou du poignet.

Une étude similaire est présentée dans [29]. Dans cette étude, des capteurs sont placés à six endroits différents (poitrine, pied, bas du dos, hanche, cuisse et poignet) et des données sont récoltées sur huit personnes différentes. Les données brutes de sept différentes activités sont collectées. Sur le même principe que l'étude précédente, un ensemble de paramètres est calculé à partir de chaque capteur pour être utilisé par quatre algorithmes de classification différents. Cette étude montre que l'algorithme des machines à vecteurs de support donne les meilleurs résultats de reconnaissance d'activités sur tous les emplacements à l'exception du pied. Les meilleurs résultats sont obtenus avec le capteur fixé à la hanche et les plus mauvais résultats sont observés quand le capteur est fixé au niveau des genoux ou des pieds.

Une dernière étude, plus récente, proposée dans [34] traite ce sujet dans le cas où les capteurs sont placés à la tête, au bras, au poignet, à la cheville, au torse, à la cuisse, sur le côté et sur le devant de la taille. Le but de cette étude est de déterminer la position optimale pour faire de la reconnaissance d'activités. 19 para-

Tableau 2 – Fréquences d'échantillonnage utilisées dans la littérature	
Fréquences d'échantillonnage (Hz)	Références
10	[17] [23]
15	[34]
16	[35]
20	[6] [22] [24]
25	[26] [35]
30	[16]
32	[7]
50	[4] [15] [36] [8] [12] [13] [37] [14]
51,2	[29]
52	[31]
68	[25]
100	[5] [38] [20] [21] [11] [27] [28]
102,4	[10]
126	[18]



mètres différents sont étudiés et huit algorithmes différents de classification sont utilisés. Le meilleur résultat est obtenu avec le capteur positionné sur le côté de la taille sur deux jeux de données : un jeu de données obtenu avec des personnes jeunes et un jeu de données obtenu avec des personnes âgées.

#### À retenir

- Les données accélérométriques peuvent être obtenues soit à partir d'un smartphone, soit d'une plateforme dédiée.
- Les données accélérométriques peuvent être combinées si nécessaire.
- Pour la reconnaissance d'activités, la fréquence d'échantillonnage est généralement comprise entre 10 Hz et 100 Hz.
- L'emplacement du capteur dépend de l'application visée.

## 3. Prétraitement des données

### 3.1 Filtrage

Les signaux fournis par les capteurs peuvent être bruités et un filtre passe-bas doit souvent être appliqué pour éliminer le bruit. Comme vu auparavant, dans certains cas il est choisi de filtrer l'accélération induite par la gravité (composante  $a_{ig}$ ) en appliquant un filtre passe-haut. Ceci est réalisé à l'aide d'un filtre de Butterworth dans [11] et un filtre passe-bande est utilisé dans [16]. Une étude est proposée dans [39] pour déterminer le filtre optimal pour réduire le bruit du signal fourni par l'accéléromètre. Plusieurs types de filtres sont mis en œuvre et comparés comme le filtre médian, le filtre de Butterworth et le filtre de Kalman.

### 3.2 Fenêtrage

Une étape de fenêtrage est souvent utilisée dans le domaine de la reconnaissance d'activités. Cette étape correspond à la **segmentation du signal en fenêtre**. Une activité et un vecteur de paramètres sont ensuite attribués à chaque fenêtre pour être utilisés par des algorithmes de classification. Un état de l'art sur les différentes techniques de fenêtrage est proposé dans [40]. Il existe trois différents types de fenêtrage : le fenêtrage défini par l'activité, le fenêtrage défini par événement et le fenêtrage par fenêtre glissante.

■ Le **fenêtrage défini par l'activité** consiste à déterminer les fenêtres en détectant les changements d'activités. Ensuite, un algorithme de reconnaissance d'activités est appliqué pour déterminer le type d'activité sur la fenêtre. Plusieurs techniques sont possibles pour déterminer le changement d'activité. Ceci peut être réalisé par une analyse fréquentielle ou, comme dans [41], par une analyse basée sur la transformée en ondelettes.

■ Le **fenêtrage par événement** a pour principe qu'un événement extérieur indique le début et la fin d'une fenêtre. Ce peut être, par exemple, un chronomètre ou un individu ou encore, comme dans [42], des interrupteurs fixés sur un pied permettant de déterminer le début et la fin des fenêtres. Cette méthode est utilisée presque exclusivement en laboratoire car il est difficile de la mettre en œuvre en situation réelle.

■ Le **fenêtrage par fenêtre glissante** est la technique la plus utilisée dans la littérature pour la reconnaissance d'activités, car elle ne nécessite pas de prétraitement de données et elle est facile d'utilisation en temps réel. Cette technique consiste à découper le signal à analyser en une suite de fenêtres de taille fixe. Un recouvrement peut être utilisé, il peut varier de 10 % à 90 %. Un

**Tableau 4 – Taille de la fenêtre**

Taille (s)	Références
1	[6] [31] [34]
1,28	[5] [11]
2	[15] [7] [28]
2,56	[19] [8] [10] [12]
3	[13]
3,2	[22]
5	[4]
5,12	[20] [21] [27]
6	[15] [17]
10	[24] [29] [38]
13	[26]

recouvrement de 50 % est par exemple utilisé dans [20]. Ce fenêtrage est particulièrement utilisé pour la reconnaissance d'activités périodiques (par exemple la marche ou la course) et pour la reconnaissance d'activités statiques (par exemple le repos). Différentes tailles de fenêtres utilisées dans la littérature sont listées dans le tableau 4.

La **taille de la fenêtre** a un impact sur la **qualité de la reconnaissance d'activités**. Ainsi, dans [40] une analyse de l'impact de taille est réalisée. Trois jeux de paramètres sont calculés sur des fenêtres allant de 0,25 seconde à 7 secondes. Ensuite, quatre algorithmes de classification sont appliqués sur les trois différents jeux de paramètres pour déterminer la longueur de fenêtre qui donne les meilleurs résultats. Cette étude montre que les fenêtres de longueur comprise entre 0,25 seconde et 2 secondes donnent les meilleures performances pour la reconnaissance d'activités et qu'il n'est donc pas nécessaire d'utiliser de larges fenêtres pour effectuer de la reconnaissance d'activités. Dans une autre étude [26], l'algorithme des forêts aléatoires est utilisé pour différencier cinq activités (le cyclisme haute et basse intensité, le repos, la position assise et l'activité ménagère). Le but de cette étude est de trouver la taille optimale de la fenêtre glissante entre des fenêtres allant de 1 seconde à 21 secondes avec 90 % de recouvrement. Les meilleurs résultats sont obtenus avec une fenêtre de 13 secondes. Dans [14], les données des capteurs d'un smartphone sont utilisées pour faire de la reconnaissance d'activités. Huit mouvements sont étudiés : la marche, le repos, la descente d'escalier, la montée d'escalier, la montée d'ascenseur, la descente d'ascenseur, la montée d'escalier mécanique et la descente d'escalier mécanique. Cinq algorithmes différents de classification sont comparés. La fenêtre optimale pour reconnaître les mouvements de cette étude se situe entre 2,5 et 3,5 secondes.

#### À retenir

- Les données brutes requièrent souvent un filtrage préalable avant exploitation.
- Les données sont segmentées en fenêtres successives, le fenêtrage par fenêtre glissante est le fenêtrage le plus courant.

## 4. Extraction et sélection de paramètres de classification

Les données de l'accéléromètre peuvent être directement utilisées par l'algorithme de classification. Par exemple, les données des trois axes de l'accéléromètre sont utilisées directement dans [37]. Cependant, dans la majorité des cas, un **ensemble de paramètres** est calculé à partir des données d'une fenêtre. Cet ensemble de paramètres va constituer un **vecteur** qui va être ensuite utilisé pour la classification. L'objectif est ici de sélectionner, parmi ces paramètres, ceux qui permettent de mieux discriminer les différentes activités.

Il est possible d'utiliser un grand nombre de paramètres ou combinaisons de paramètres, cependant, il est préférable d'en utiliser le moins possible car si on utilise des variables inappropriées ou redondantes, on augmente la charge de calculs et on réduit les performances des algorithmes de classification. Il existe un très grand nombre de paramètres possibles. Les articles suivants énumèrent les paramètres souvent utilisés en reconnaissance d'activités : [1], [43] et [3]. Ces paramètres peuvent être calculés à partir de l'accélération de chaque axe  $a_x$ ,  $a_y$  et  $a_z$ , de la norme  $a_n$ , des angles de rotation ou des normes définies sur un plan  $a_{xy}$ ,  $a_{yz}$  et  $a_{xz}$ . Les paramètres les plus utilisés sont présentés dans la suite, ils sont répertoriés dans le tableau 5.

Dans la suite,  $s$  désigne le signal sur lequel sont calculés les paramètres.  $s$  peut correspondre à  $a_x$ ,  $a_y$ , etc. Ce signal  $s$  est disponible sur une certaine fenêtre de temps,  $N$  est le nombre d'échantillons disponibles sur cette fenêtre de temps et  $s(t)$  est la valeur de l'échantillon du signal  $s$  à l'instant  $t$ , avec  $t \in \{1; 2; \dots; N\}$ .

### 4.1 Liste des paramètres usuels

#### 4.1.1 Moyenne, variance et écart type

Un des paramètres les plus simples et intuitifs est la **moyenne**. Le calcul de ce paramètre nécessite très peu de calculs. Il permet aussi de lisser le signal et d'atténuer le bruit. C'est un des paramètres les plus souvent utilisés dans la littérature. La moyenne est définie de la manière suivante :

$$\mu_s = \frac{1}{N} \sum_{t=1}^N s(t) \quad (9)$$

La **variance** est aussi une variable souvent utilisée pour la reconnaissance d'activités. Cette variable sert à caractériser la dispersion des données. L'**écart type** correspond à la racine carrée de la variance et donne les mêmes informations que la variance. La variance ou l'écart type seront moins intéressants à utiliser si le signal contient de nombreuses valeurs aberrantes, celles-ci ayant un impact important sur le calcul de ces paramètres. La variance est définie de la manière suivante :

$$\sigma_s^2 = \frac{1}{N} \sum_{t=1}^N (s(t) - \mu_s)^2 \quad (10)$$

À partir de l'écart type calculé sur chacun des axes, il est possible de calculer la **magnitude de l'écart type** (utilisée dans [34]). Elle est définie par :

$$\text{magnitude de l'écart type} = \sqrt{\sigma_{a_x}^2 + \sigma_{a_y}^2 + \sigma_{a_z}^2} \quad (11)$$

**Tableau 5 – Paramètres usuellement utilisés**

Paramètres	Références
Moyenne	[4] [5] [31] [15] [6] [29] [38] [36] [17] [18] [19] [9] [22] [24] [26] [10] [34] [11] [25] [14]
Variance	[4] [5] [36] [7] [18] [11] [14]
Écart type	[5] [31] [15] [6] [29] [38] [17] [19] [22] [9] [24] [26] [10] [34] [11] [25] [12] [14]
Moyenne quadratique	[4] [5] [31] [17] [7] [10] [11]
Moyenne des valeurs absolues	[17] [22] [23] [9] [24] [26] [10] [27]
Entropie	[4] [36] [17] [18] [22] [24] [10] [25] [12]
Temps entre pics	[5] [11]
Nombre de pics	[5] [17] [11]
Coefficients de corrélation	[5] [31] [15] [6] [29] [22] [9] [24] [26] [10] [34] [11] [25]
Étendue de mesure	[4] [5] [7] [10] [34] [11]
Différence des moyennes	[18] [14]
Minimum	[6] [17] [19] [34] [11] [12]
Maximum	[6] [17] [7] [19] [34] [11] [12]
Médiane	[26] [25] [14]
Percentile	[6] [38] [14]
Énergie	[4] [15] [29] [17] [10] [11] [25] [27]
Coefficient d'asymétrie	[4] [31] [15] [29] [38] [7] [18] [9] [10] [12]
Kurtosis	[4] [31] [15] [29] [38] [10] [12]
Coefficients du modèle autorégressif	[20] [22] [23] [9] [24]
Coefficients transformée en ondelettes	[31] [6] [38] [35] [25]
Coefficients transformée de Fourier	[4] [15] [6] [38] [36] [18] [26] [10] [25] [14]
Zero crossing mode	[15]

où  $\sigma_{a_x}^2$ ,  $\sigma_{a_y}^2$  et  $\sigma_{a_z}^2$  sont les variances suivant les axes  $x$ ,  $y$  et  $z$  de l'accéléromètre.

La **valeur absolue des écarts** est un autre paramètre qui est utilisé pour mesurer la dispersion (utilisée dans [2]). Ce paramètre est défini par :

$$\text{valeur absolue des écarts} = \frac{1}{N} \sum_{t=1}^N |s(t) - \mu_s| \quad (12)$$

Dans [18], une fenêtre de temps de 6 secondes est utilisée. Cette fenêtre est ensuite découpée en sous-fenêtre de 0,5 seconde sans recouvrement. Avec ces sous-fenêtres, il est proposé de calculer la tendance moyenne comme suit :

$$\text{tendance moyenne} = \sum_{k=2}^j \left( \left| \mu_{s[k]} - \mu_{s[k-1]} \right| \right) \quad (13)$$

où  $j$  est le nombre de sous-fenêtres dans la fenêtre de base,  $\mu_{s[k]}$  est la moyenne de la  $k$ -ème sous-fenêtre fille.

À partir de ces sous-fenêtres, d'autres paramètres sont calculés dans [18] comme la **différence des moyennes** :

$$\text{différence des moyennes} = \sum_{k=1}^j \left( \left| \mu_s - \mu_{s[k]} \right| \right) \quad (14)$$

Ces mêmes paramètres peuvent aussi être calculés relativement à la variance.

#### 4.1.2 Médiane, percentile, maximum, minimum et éventail

La **médiane** est la valeur qui permet de séparer un ensemble d'échantillons en deux parties égales : une partie composée de tous les échantillons avec les valeurs les plus élevées et une autre partie composée de tous les échantillons avec les valeurs les moins élevées.

Le **percentile** est une mesure qui indique la valeur où on peut trouver un pourcentage des observations. Par exemple, le 25<sup>e</sup> percentile correspond à la valeur où on trouve 25 % des observations en dessous de cette valeur et le 50<sup>e</sup> percentile correspond à la médiane.

Le **maximum** ou le **minimum** sur une fenêtre temporelle sont des paramètres faciles à calculer. À partir de ces deux valeurs, il est aussi possible de calculer l'**éventail** qui est la différence entre le maximum et le minimum :

$$M = \max_{t \in [1;N]} s(t) \quad (15)$$

$$m = \min_{t \in [1;N]} s(t) \quad (16)$$

$$\Delta_M = M - m \quad (17)$$

La **déviati on absolue médiane** mesure la variabilité d'un signal, cette mesure est utilisée dans [10] et est définie par :

$$\text{déviation absolue médiane} = \text{médiane}_{t \in [1;N]} (|s(t) - \text{médiane}_s|) \quad (18)$$

#### 4.1.3 Corrélation

Le **coefficient de corrélation** est utilisé pour mesurer l'intensité de la relation linéaire entre deux signaux. Le coefficient de corrélation le plus utilisé est celui de Bravais-Pearson. Pour deux signaux  $s$  et  $r$ , ce paramètre est défini comme suit :

$$\rho_{s,r} = \frac{1}{N\sigma_s\sigma_r} \sum_{t=1}^N (s(t) - \mu_s)(r(t) - \mu_r) \quad (19)$$

ou plus généralement :

$$\rho_{s,r}(i) = \frac{1}{(N-1)\sigma_s\sigma_r} \sum_{t=i+1}^N (s(t) - \mu_s)(r(t-i) - \mu_r) \quad (20)$$

$\rho_{s,r}(i)$  mesure la similarité des signaux  $s$  et  $r$  décalés de  $i$  échantillons. Le maximum de corrélation  $\max_{i \in [0;N-1]} \rho_{s,r}(i)$  peut aussi être utilisé, comme dans [44].

#### 4.1.4 Autres paramètres dans le domaine temporel

La **moyenne quadratique** correspond à la racine carrée de la moyenne du signal au carré. Pour un signal de moyenne nulle, la moyenne quadratique et l'écart type sont équivalents. Cette métrique est souvent utilisée dans la reconnaissance d'activités et elle est définie par :

$$\text{moyenne quadratique} = \sqrt{\frac{1}{N} \sum_{t=1}^N s(t)^2} \quad (21)$$

Ce paramètre est similaire à l'**énergie** définie par :

$$\text{énergie} = \sum_{t=1}^N s(t)^2 \quad (22)$$

Des paramètres d'actimétrie peuvent aussi être utilisés comme le **zero crossing mode (ZCM)**. Il s'agit du nombre de fois que le signal change de signe. Le seuil peut être remplacé par la moyenne ou un seuil quelconque dans certaines études. Ce paramètre est utilisé par exemple en analyse de sommeil (utilisé dans [45]). Un autre paramètre utilisé en actimétrie est le **time above threshold** qui correspond au nombre de points au-dessus d'un seuil.

D'autres paramètres peuvent être calculés à l'aide des pics qui correspondent à des points dont la valeur est supérieure à celles des points le suivant et le précédant. Le nombre de pics d'une fenêtre ou le temps moyen entre deux pics peuvent être utilisés comme paramètres. Ces paramètres sont utiles pour la caractérisation des activités périodiques comme la marche ou la course.

L'**aire d'amplitude du signal** correspond à la moyenne des valeurs absolues des accélérations  $a_x$ ,  $a_y$  et  $a_z$  sur les trois axes et sur une période de temps. Il est défini par :

$$\text{aire d'amplitude du signal} = \frac{1}{N} \left( \sum_{t=1}^N |a_x(t)| + \sum_{t=1}^N |a_y(t)| + \sum_{t=1}^N |a_z(t)| \right) \quad (23)$$

Le **coefficient d'asymétrie** et le **kurtosis** sont des paramètres de forme. Le coefficient d'asymétrie permet de mesurer la symétrie du signal. Si le coefficient est négatif, le signal sera plus présent sur la droite de la médiane et si le coefficient est positif, le signal sera plus présent sur la gauche de la médiane. Le kurtosis, ou coefficient d'amortissement, permet de mesurer la dispersion des valeurs du signal. Le coefficient d'asymétrie et le kurtosis sont définis par :

$$\text{coefficient d'asymétrie} = \frac{1}{N} \sum_{t=1}^N \frac{(s(t) - \mu_s)^3}{\sigma_s^3} \quad (24)$$

$$\text{kurtosis} = \frac{1}{N} \sum_{t=1}^N \frac{(s(t) - \mu_s)^4}{\sigma_s^4} \quad (25)$$

#### 4.1.5 Transformée de Fourier et transformée en ondelettes

La plupart des activités génèrent des signaux périodiques comme la marche ou la course. Il peut donc être utile de réaliser une analyse dans le domaine fréquentiel pour différencier les activités. L'outil principal utilisé pour l'analyse de fréquence est la **transformation de Fourier discrète (TFD)** qui permet de calculer



une représentation spectrale discrète d'un signal. La TFD est définie à partir des échantillons  $s(t)$  comme suit :

$$S(f) = \sum_{t=1}^N s(t) e^{-j \frac{2\pi f(t-1)}{N}} \quad (26)$$

où  $f$  désigne la fréquence.

Le calcul de la TFD est généralement réalisé *via* la transformée de Fourier rapide (pour réduire la charge de calcul). Tous les coefficients de la TFD ne doivent pas nécessairement être analysés. Seuls certains de ces coefficients peuvent être choisis selon leur utilité à discriminer certains mouvements ou selon leur amplitude.

L'entropie peut être utilisée pour différencier deux mouvements qui ont une signature différente. Elle se calcule *via* la TFD comme suit :

$$\text{entropie} = \frac{1}{N} \sum_{f=1}^N |S(f)|^2 \log(|S(f)|^2) \quad (27)$$

Comme pour la transformée de Fourier, la **transformée en ondelettes discrète** permet de décomposer un signal avec la particularité de réaliser cette décomposition dans le domaine temps et fréquence ([46], [47]). Une **ondelette** est une forme d'onde avec une valeur moyenne nulle et d'une durée limitée. Il est possible d'utiliser différentes ondelettes, les plus utilisées sont les ondelettes de Daubechies, Symlet, Coiflet, biorthogonales et biorthogonales réversibles. Des exemples d'usage de la transformée en ondelettes discrète en reconnaissance d'activité sont détaillés dans [48], [49], [25] et [35].

#### 4.1.6 Modèle autorégressif

Un modèle autorégressif permet une modélisation structurelle du signal. Ce modèle établit la relation de récurrence suivante entre échantillons  $s(t)$ ,  $s(t-1)$ , ...,  $s(t-p)$  :

$$s(t) = -\phi_1 s(t-1) - \dots - \phi_p s(t-p) + e(t) \quad (28)$$

où  $e(t)$  est un bruit blanc (le bruit générateur),  $p$  est l'ordre du modèle et les  $\phi_i$  sont les paramètres du modèle. Ces paramètres peuvent être estimés *via* les équations de Yule-Walker, ils peuvent ensuite servir comme variables pour la classification, c'est le cas dans [20].

## 4.2 Sélection des paramètres

Comme vu auparavant, bon nombre de paramètres peuvent être calculés à partir des données. Il n'existe pas de consensus sur le choix des paramètres dans la littérature et il n'est pas opportun d'utiliser tous les paramètres présentés précédemment. Le choix des paramètres est souvent motivé par le **type de mouvement à reconnaître** et des **ressources matérielles disponibles** pour calculer les paramètres. Par exemple, le calcul des paramètres de la transformée de Fourier est beaucoup plus lourd que le calcul des paramètres comme le minimum, le maximum ou la moyenne. La charge de calcul de différents paramètres est exposé dans [43]. En outre, il est aussi important de **réduire le plus possible le nombre de paramètres pour diminuer les besoins en calcul de l'algorithme de classification** et éviter les **informations redondantes** qui pourraient dégrader les résultats de la classification.

Il existe plusieurs méthodes possibles pour la sélection des paramètres. Un ensemble de méthodes de sélection de paramètres consiste à sélectionner les paramètres les plus pertinents à partir de l'ensemble des paramètres de départ. Cet ensemble de méthodes est présenté dans [50] et consiste à suivre la procédure itérative présentée par la figure 2.

Les **différentes méthodes de sélection** vont dépendre de l'évaluation des sous-ensembles des paramètres et de la génération de

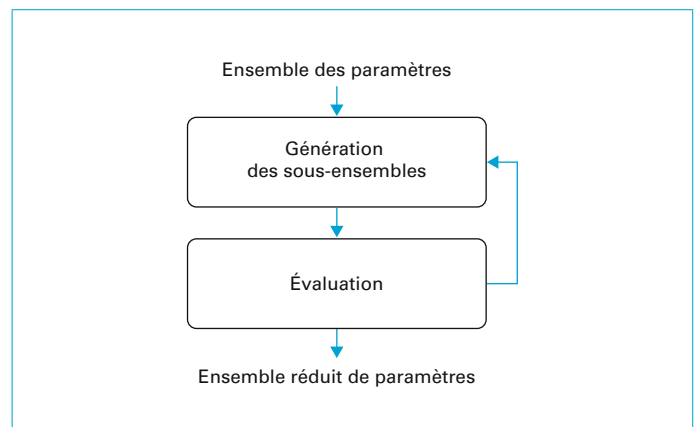


Figure 2 – Procédure pour la sélection des paramètres

ces sous-ensembles de paramètres. Il existe trois méthodes principales pour la génération des sous-ensembles :

- la **génération exhaustive** : tous les sous-ensembles de paramètres sont testés. Cette méthode permet de trouver la solution optimale. Cependant, le test de tous les sous-ensembles nécessite beaucoup de calcul pour un grand nombre de paramètres. Cette méthode n'est pas utilisable avec un nombre de paramètres trop important ;

- la **génération heuristique** : des paramètres sont supprimés ou ajoutés à chaque essai jusqu'à trouver la solution optimale. Cette méthode regroupe trois sous-catégories :

- 1/ **Forward** : le sous-ensemble de départ est vide et des paramètres sont rajoutés à chaque itération,
- 2/ **Backward** : le sous-ensemble de départ contient tous les paramètres et des paramètres sont enlevés à chaque itération,
- 3/ **Stepwise** : cette catégorie est le mélange des deux approches. Des paramètres sont ajoutés ou supprimés du sous-ensemble à chaque itération ;

- la **génération aléatoire** : un nombre de sous-ensembles est généré aléatoirement. On détermine ensuite le meilleur sous-ensemble parmi ce groupe. Cette méthode nécessite moins de calcul que la génération exhaustive car elle ne parcourt pas toutes les possibilités de sous-ensembles.

Il existe **deux approches** possibles pour l'**évaluation des sous-ensembles** :

- l'**approche filter** : un score va être attribué à chaque paramètre en fonction de son utilité pour la classification. L'évaluation se fait indépendamment de l'algorithme de classification et plusieurs types de score peuvent être utilisés ;

- l'**approche wrapper** : l'algorithme de classification est utilisé pour sélectionner les paramètres. L'avantage de cette méthode par rapport à la méthode **filter** est de prendre en compte l'algorithme d'apprentissage pour sélectionner les paramètres. Cette méthode nécessite par contre plus de temps de calcul et doit être mise à jour si un autre algorithme de classification est utilisé.

Dans [18], une approche **filter** et une approche **wrapper** sont comparées pour la sélection des paramètres. Dans cet article, l'algorithme pour l'approche **filter** est le Relief-F. La méthode Relief, présentée par [51], utilise une approche statistique avec une génération heuristique. Cette méthode a été améliorée en Relief-F par [52] pour l'utiliser dans des problèmes de classification multiclasse et réduire la sensibilité de l'algorithme au bruit. Le deuxième algorithme, celui utilisant l'approche **wrapper**, est le *Sequential Forward Floating Search* présenté dans [53]. Au départ, un ensemble de 31 paramètres sont utilisés pour la classification, l'approche **filter** a sélectionné un ensemble de 21 paramètres pour un premier algorithme de classification et un ensemble de 30 paramètres pour un second algorithme de classification. L'approche **wrapper** permet de sélectionner 11 paramètres

pour le premier algorithme de classification et 12 paramètres pour le second. Dans cette étude, l'approche *wrapper* permet de mieux réduire le nombre de paramètres pour la classification.

Dans [54], deux autres méthodes de sélection de paramètres sont étudiées pour déterminer les paramètres les plus utiles pour la reconnaissance d'activités. Une des méthodes utilise une génération aléatoire avec l'algorithme *Las Vegas Filter* présenté dans [55]. Le but est de choisir, de façon aléatoire, le sous-ensemble des caractéristiques ayant la plus petite mesure d'inconsistance.

La **mesure d'inconsistance** est définie par le rapport du nombre de points inconsistants sur le nombre de points total. Dans le cas de la reconnaissance d'activités, deux points sont dits « inconsistants » s'ils possèdent les mêmes valeurs de paramètres mais ne décrivent pas la même activité.

D'autres types d'algorithmes sont utilisés pour la sélection de paramètres comme un algorithme génétique. Cet algorithme est inspiré de la théorie de Darwin et est décrit plus en détail dans [56]. Cet algorithme est utilisé dans [57] pour faire une comparaison entre deux groupes de paramètres : le premier groupe regroupe les paramètres souvent utilisés dans la reconnaissance d'activités tels que la moyenne, la variance et les coefficients de la TFD. Le second groupe correspond à des paramètres calculés à partir des pics du signal et du ZCM. Un algorithme génétique est ensuite utilisé pour la sélection des paramètres avant d'effectuer une classification pour comparer les performances des deux groupes de paramètres.

Les méthodes précédentes consistent toutes à **sélectionner les paramètres les plus pertinents** parmi l'ensemble de paramètres de départ. Une autre approche possible consiste à **réduire la dimension de l'ensemble des paramètres de départ** en transformant cet ensemble en un sous-ensemble de dimension plus petit en construisant de nouveaux paramètres à partir de combinaisons linéaires des paramètres de départ. Les nouveaux paramètres sont choisis pour ne pas être corrélés et maximiser la dispersion des points. Plus de détails sur l'analyse des composantes sont disponibles dans [58]. Une méthode dérivée de l'analyse des composantes principales est par exemple utilisée dans [27] pour de la reconnaissance d'activités.

Enfin, l'**analyse discriminante linéaire** est une autre méthode utilisée pour la réduction des dimensions et consiste à choisir des combinaisons linéaires des paramètres pour maximiser l'homogénéité de chaque classe. L'analyse discriminante linéaire est par exemple utilisée dans [22] pour la réduction de la dimension du vecteur de paramètres (voir section suivante).

### 4.3 Normalisation des paramètres

Les différents paramètres choisis peuvent avoir des éventails de valeurs très différents. Une étape de normalisation est nécessaire avant de pouvoir utiliser les paramètres pour la classification. Il existe plusieurs types de normalisation. Pour la suite, on suppose disposer d'une série de paramètres  $\{(p_{1/1}, p_{2/1}, \dots), (p_{1/2}, p_{2/2}, \dots), \dots, (p_{1/L}, p_{2/L}, \dots)\}$  où  $L$  est la longueur de la série et  $p_{ij}$  est le  $i$ -ième paramètre (moyenne, écart type, etc.) calculé sur la  $j$ -ième fenêtre.

Dans [57], la normalisation « min-max » est utilisée. Cette normalisation consiste à calculer tous les paramètres pour qu'ils soient compris entre 0 et 1. La formule utilisée est :

$$p_{ij}^{(norm)} = \frac{p_{ij} - \min_{j \in [1;L]} (p_{ij})}{\max_{j \in [1;L]} (p_{ij}) - \min_{j \in [1;L]} (p_{ij})} \quad (29)$$

où  $p_{ij}^{(norm)}$  est le paramètre normalisé entre 0 et 1.

D'autres types de normalisation peuvent être utilisés. L'expression suivante présente une normalisation basée sur la moyenne :

$$p_{ij}^{(norm)} = \frac{p_{ij} - \mu_{p_i}}{\max_{j \in [1;L]} (p_{ij}) - \min_{j \in [1;L]} (p_{ij})} \quad (30)$$

où  $\mu_{p_i} = \frac{1}{L} \sum_{j=1}^L p_{ij}$  est la moyenne sur le paramètre  $p_{ij}$ .

La normalisation suivante est parfois aussi utilisée et fait intervenir la variance et la moyenne du paramètre :

$$p_{ij}^{(norm)} = \frac{p_{ij} - \mu_{p_i}}{\sigma_{p_i}} \quad (31)$$

où  $\sigma_{p_i}$  est l'écart type sur le paramètre  $p_{ij}$ . Cette normalisation est par exemple utilisée dans [6] et [28].

#### À retenir

- Des paramètres sont calculés sur chaque fenêtre de données. Il existe un grand nombre de paramètres possibles, certains plus habituels que d'autres.
- Ces paramètres doivent être choisis de manière à décrire significativement l'activité réalisée.
- Il est possible de mettre en œuvre un algorithme de sélection de paramètres afin d'éliminer les paramètres redondants ou inutiles.
- Les paramètres calculés doivent être normalisés.

## 5. Classification

La **classification** consiste à associer chaque donnée à une classe, les classes correspondant dans notre cas aux activités. L'algorithme réalisant la classification est un **classifieur**. Il existe deux types de classification :

- la **classification supervisée** : un ensemble de données dont la classe d'appartenance est connue est disponible. Cet ensemble de données va permettre de construire le modèle du classifieur, modèle qui sera utilisé par la suite pour déterminer la classe de nouvelles données ;
- la **classification non supervisée** : la classe d'aucune donnée n'est connue au départ. L'objectif est la recherche d'une répartition visant à regrouper les individus dans des classes. Cette répartition est réalisée de manière à avoir les classes les plus homogènes et les plus distinctes les unes des autres possible.

La classification non supervisée est parfois utilisée pour la reconnaissance d'activités, par exemple dans [59]. Cependant, la classification supervisée est de loin la plus utilisée dans la reconnaissance d'activités. Un **algorithme de classification supervisée** est organisé en deux étapes :

- l'étape d'**apprentissage** : le but est d'apprendre un modèle de répartition à l'aide de données étiquetées (la base d'apprentissage) ;
- l'étape de **décision** : le modèle construit à l'étape précédente est utilisé pour estimer la classe de nouvelles données.

Bien qu'il existe des études comparatives d'algorithmes de classification en termes de reconnaissance d'activités (voir [60] et [61] par exemple), ici encore il n'y a pas de consensus sur l'algorithme de classification à utiliser. Le tableau 6 énumère les principaux algorithmes de classification supervisée en reconnaissance d'activités, ces algorithmes sont présentés ci-après. Pour la suite, on admet donc

**Tableau 6 – Algorithmes de classification utilisés en reconnaissance d'activités**

Algorithmes	Références
Plus proches voisins	[4] [6] [60] [17] [7] [19] [18] [8] [10] [34] [25] [14]
Naïve bayésienne	[4] [29] [38] [7] [18] [35] [10] [34] [14]
Séparateur à vaste marge	[5] [6] [29] [60] [16] [17] [7] [19] [20] [21] [8] [9] [10] [35] [34] [11] [12] [14] [28]
Réseau de neurones	[5] [29] [60] [22] [23] [24] [35] [10] [34] [13] [27] [62] [63] [64]
Analyse discriminante	[7] [19]
Arbre de décision	[5] [29] [36] [17] [7] [19] [10] [34] [14]
Forêt aléatoire	[5] [31] [15] [6] [17] [26] [12] [13]

qu'un ensemble d'exemples est à disposition pour l'apprentissage. On définit  $\{(x_1, y_1), (x_2, y_2), \dots, (x_L, y_L)\}$  l'ensemble des points de la base d'apprentissage de longueur  $L$ .  $y_i$  est un vecteur de dimension  $D$ , les  $D$  composantes  $y_i(d)$  de ce vecteur (avec  $d \in \{1, 2, \dots, D\}$ ) correspondent à des paramètres calculés à la section précédente et sélectionnés pour la classification.  $x_i \in \{1, 2, \dots, K\}$  où  $K$  est le nombre de classes possibles et, en termes de reconnaissance d'activités,  $K$  représente le nombre d'activités possibles. Ainsi, au sein de cette base d'apprentissage, à chaque point  $y_i$  est associé une classe d'appartenance  $x_i$ . L'objectif dans la suite est la détermination de la classe d'appartenance d'un nouveau point  $y$  potentiellement hors de la base d'apprentissage.

## 5.1 Classification par les plus proches voisins

La **méthode des plus proches voisins** est un algorithme de classification supervisé intuitif qui se base sur l'exploration, dans la base d'apprentissage, du voisinage du nouveau point à classer. La particularité de cette méthode est qu'elle ne nécessite pas de phase d'apprentissage pour apprendre un modèle, le modèle est constitué des données d'apprentissage.

Pour utiliser cette méthode, l'utilisateur doit choisir un nombre entier  $N_{voisins}$  et un mode de calcul de distance. Pour déterminer la classe d'appartenance du point  $y$ , il suffit de calculer les distances entre ce point et les points de la base d'apprentissage. La classe majoritaire parmi les  $N_{voisins}$  points les plus proches est attribuée au point  $y$ . Notons que la distance entre deux points peut être appréhendée de différentes manières (distance euclidienne, distance de Manhattan, distance de Minkowski, etc.). La **distance euclidienne** reste la distance la plus utilisée.

L'inconvénient principal de cette méthode est que la classification d'un nouveau point requiert un temps de calcul important. Un autre inconvénient est que tous les points de la base d'apprentissage doivent être stockés pour pouvoir être utilisés pour la classification, enfin le résultat de la classification est très fortement lié à

la base d'apprentissage et au choix sur  $N_{voisins}$  du nombre de plus proches voisins à scruter.

## 5.2 Classification naïve bayésienne

La classification naïve bayésienne suit une approche probabiliste et se base sur la formule de Bayes :

$$P(x = k|y) = \frac{P(y|x = k)P(x = k)}{P(y)} \quad (32)$$

où  $P(x = k|y)$  est la probabilité de la classe  $k$  sachant les paramètres  $y$ ,  $P(x = k)$  est la probabilité de la classe  $k$ ,  $P(y|x = k)$  est la probabilité des paramètres  $y$  sachant la classe  $k$  et  $P(y)$  est la probabilité des paramètres  $y$ . La classification naïve bayésienne a pour hypothèse forte que tous les paramètres sont indépendants les uns des autres. On peut ainsi écrire :

$$P(y|x = k) = \prod_{d=1}^D P(y(d)|x = k) \quad (33)$$

À partir de l'expression (32) ceci donne :

$$P(x = k|y) = \frac{P(x = k) \prod_{d=1}^D P(y(d)|x = k)}{P(y)} \quad (34)$$

La classification du nouveau point  $y$  est ainsi réalisée en calculant chaque probabilité  $P(x = k|y)$  pour  $k \in \{1, 2, \dots, K\}$  en utilisant une hypothèse de distribution gaussienne pour les lois de probabilités des composantes de  $y$  et en choisissant ensuite la classe affectée de la plus forte probabilité. L'avantage de la classification naïve bayésienne est sa simplicité de mise en œuvre, son inconvénient est l'hypothèse d'indépendance sur laquelle est basée la méthode, hypothèse rarement valide.

## 5.3 Classification par séparateur à vaste marge (SVM)

L'algorithme SVM est un algorithme de classification supervisé souvent utilisé pour la classification d'activités. Cet algorithme est utilisé par exemple dans [20] en utilisant les paramètres d'un modèle autorégressif comme entrée du classifieur. Dans [21], la transformée en cosinus discrète est utilisée comme entrée pour la classification par SVM. Le but de cet algorithme est de déterminer un hyperplan séparateur à marges maximales entre deux classes. Cet algorithme est décrit dans [65]. Dans le cas linéaire et dans le cas d'une classification en deux classes ( $x_i = 1$  ou  $x_i = -1$ ), le vecteur de paramètres  $w$  (de dimension  $D$ ) de l'hyperplan séparateur optimal est déterminé par la minimisation de la fonction suivante :

$$\min \left\{ \frac{1}{2} \|w\|^2 \right\} \quad (35)$$

tel que  $x_i(w^T y_i + b) \geq 1$ ,  $i = 1, 2, \dots, L$

où  $b$  est un scalaire.

L'étape d'apprentissage va permettre l'estimation du vecteur de paramètres  $w$  de l'hyperplan séparateur. Ensuite, lors de l'étape de décision, il suffit de déterminer la position du nouveau point  $y$  relativement à l'hyperplan séparateur pour connaître la classe de ce point. La mise en œuvre de cette étape de décision sur un objet connecté est donc relativement aisée. Différents détails techniques et variantes sont disponibles dans [65].

## 5.4 Classification par réseau de neurones

Le **réseau de neurones** est un algorithme de classification inspiré par le fonctionnement des neurones biologiques. Un réseau de neurones est constitué d'un assemblage plus ou moins complexe de neurones formels.

Le neurone formel est défini par une fonction d'activation  $g(\cdot)$  et des entrées  $e_1, \dots, e_p$ . La sortie du neurone  $s$  est calculée à partir de :

$$s = g\left(w_0 + \sum_{i=1}^p w_i e_i\right) \quad (36)$$

où  $w_0$  est une constante appelée « biais du neurone » et les  $w_1, \dots, w_p$  représentent le poids associé à chaque entrée  $e_i$ . Ces paramètres sont calculés durant l'étape d'apprentissage, ceci pour chaque neurone du réseau.

Comme illustré sur la figure 3, les neurones sont regroupés en couches et les couches sont reliées entre elles. La sortie d'une couche correspond à l'entrée d'une autre. La dernière couche détermine la classe en calculant une probabilité d'appartenance. Il existe de nombreux types de réseaux de neurones.

Un **type de réseaux de neurones** est défini par le choix du nombre de couches, du type de neurones de chaque couche, la nature de l'interaction entre les couches et de l'algorithme d'apprentissage utilisé.

Une des structures les plus répandues est le perceptron multicouche, représenté sur la figure 3. Un perceptron multicouche est un réseau constitué de plusieurs couches successives. La première couche a pour fonction de lire les entrées et la dernière couche de fournir la sortie. Une ou plusieurs couches cachées sont situées entre la couche d'entrée et la couche de sortie. Dans [62], plusieurs types de réseaux de neurones sont comparés pour faire de la reconnaissance d'activités.

## 5.5 Classification par analyse discriminante

L'**analyse discriminante** est une technique statistique qui permet la détermination d'une frontière entre les différentes classes. C'est une version plus générale de la classification naïve bayésienne. On considère que les variables d'entrée de la classification suivent toutes une distribution normale. Les frontières sont déterminées à partir des barycentres des différentes classes et la matrice de covariance.

Le fonctionnement de l'analyse discriminante est décrit plus en détail dans [66]. La prédiction d'une classe est obtenue, comme précédemment, en utilisant la formule de Bayes :

$$P(x = k|y) = \frac{P(y|x = k)P(x = k)}{P(y)} \quad (37)$$

Il est supposé ici, via la loi normale, que  $P(y|x = k)$  peut s'exprimer comme suit :

$$P(y|x = k) = \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma_k|^{\frac{1}{2}}} e^{-\frac{1}{2}(y - \mu_k)^T \Sigma_k^{-1}(y - \mu_k)} \quad (38)$$

où  $\mu_k$  est la moyenne des paramètres de la classe  $k$  et  $\Sigma_k$  est la matrice de covariance de la classe  $k$ .




Figure 3 – Exemple d'un réseau avec une couche cachée

Comme pour la classification naïve bayésienne, la classification du nouveau point  $y$  est réalisée en calculant chaque probabilité  $P(x = k|y)$  pour  $k \in \{1, 2, \dots, K\}$  et en choisissant ensuite la classe affectée de la plus forte probabilité.

L'apprentissage du modèle consiste en l'estimation de la moyenne  $\mu_k$  de chaque classe et de la matrice de covariance  $\Sigma_k$ . Dans l'analyse discriminante linéaire, les matrices de covariance sont supposées identiques pour toutes les classes. Les paramètres sont calculés à partir de :

$$\mu_k = \frac{1}{L_k} \sum_{i|x_i=k} y_i \quad (39)$$

$$\Sigma = \frac{1}{L} \sum_{k=1}^K \sum_{i|x_i=k} (y_i - \mu_k)(y_i - \mu_k)^T \quad (40)$$

où  $L_k$  est le nombre de points d'apprentissage de la classe  $k$  ( $L_k$  est tel que  $\sum_{k=1}^K L_k = L$ ).

Dans le cas de l'analyse discriminante quadratique, chaque classe a une matrice de covariance différente qui est déterminée par :

$$\Sigma_k = \frac{1}{L_k} \sum_{i|y_i=k} (y_i - \mu_k)(y_i - \mu_k)^T \quad (41)$$

## 5.6 Classification par arbre de décision

Un **arbre de décision** est un modèle hiérarchique constitué de nœuds et de feuilles. Chaque nœud correspond à une condition sur un paramètre et un arbre est constitué d'une série de nœuds qui permet de finir sur une feuille avec une classe attribuée.

Le but de l'apprentissage est de définir les différents nœuds et la classe des feuilles. Un algorithme usuel pour cette phase d'apprentissage est le CART présenté dans [67]. Cet algorithme



est composé de trois étapes successives. La première étape est la construction d'un arbre binaire maximal (l'arbre maximal est composé d'autant de feuilles que de points dans la base d'apprentissage). Pour cette étape, il est nécessaire de choisir un critère de construction, une règle d'arrêt et une règle d'affectation. Le **critère de construction** va définir les différents nœuds de l'arbre en utilisant une fonction d'hétérogénéité comme la concentration de Gini ou l'entropie. Différentes fonctions d'hétérogénéité sont comparées dans [68]. La **règle d'arrêt** va permettre d'arrêter la construction de l'arbre en déterminant si le nœud actuel est une feuille. La **règle d'affectation** attribue une classe aux feuilles de l'arbre.

L'arbre maximal obtenu n'est pas directement utilisable, car il possède un nombre trop important de feuilles et est très dépendant aux données d'apprentissage utilisées. La deuxième étape de l'algorithme a pour objectif d'élaguer l'arbre pour réduire le nombre de feuilles et le rendre moins fidèle aux données d'apprentissage. Cette étape va permettre de construire un ensemble de sous-arbres de l'arbre maximal et de choisir l'arbre le plus performant parmi cet ensemble. Le CART n'est pas le seul algorithme d'apprentissage par arbre de décision. Par exemple, l'algorithme C4.5 est utilisé dans [2]. Cet algorithme a été présenté dans [69] et il est une amélioration de l'algorithme ID3 présenté dans [70].

L'avantage de l'apprentissage par arbre de décision est qu'il est facilement interprétable par les utilisateurs. De plus, l'utilisation de l'arbre de décision nécessite peu de calcul et peut donc être facilement embarqué sur un objet connecté qui possède peu de ressources de calcul. Néanmoins la classification par arbre de décision est sensible à l'ordre des données d'apprentissage et sujette au surapprentissage.

## 5.7 Classification par les forêts aléatoires

Les **forêts aléatoires** est un algorithme de classification proposé dans [71] et [72] et basé sur l'apprentissage par arbre de décision. Cette méthode consiste à construire plusieurs arbres de décision à partir de bases de données d'apprentissage différentes. Les bases de données sont construites en tirant au sort des échantillons à partir de la base de données de départ. Comme l'apprentissage par arbre de décision est très sensible aux données d'apprentissage, tous les arbres de décisions sont différents. La classe prédite finale est la classe prédite par le plus d'arbres de décision.

La particularité des forêts aléatoires est d'utiliser l'algorithme CART légèrement modifié pour la création des nœuds : le critère de construction pour l'élaboration des nœuds utilise une partie des paramètres disponibles, partie choisie de manière aléatoire.

Cet algorithme a été utilisé dans [26] pour différencier cinq activités différentes (le cyclisme haute intensité et basse intensité, les tâches ménagères, le repos et la position assise). Le meilleur résultat est obtenu avec un taux de reconnaissance d'activités de 89,6 % à partir d'une forêt de 64 arbres et d'un fenêtrage de 13 secondes avec 90 % de recouvrement.

## 5.8 Combinaison d'algorithmes de classification

Dans la plupart des cas, un seul algorithme de classification est utilisé pour faire de la reconnaissance d'activités. Cependant, plusieurs algorithmes de classification peuvent être utilisés en combinaison pour améliorer les résultats. Par exemple, dans [10] trois algorithmes de classification sont utilisés : SVM, arbre de décision et plus proches voisins. Chaque algorithme propose une classe d'appartenance pour le point en cours de prédiction, le résultat final est la classe majoritaire. Cette méthode est appelée

la « fusion des décisions ». L'avantage de cette méthode est d'améliorer le résultat de la classification, comme le montre [10]. Cependant, cette technique nécessite plus de temps de calcul. Le vote majoritaire n'est pas le seul type de fusion de décision. Un autre type de fusion de décision est une moyenne des probabilités des algorithmes de classification, ceci est utilisé dans [5].

D'autres approches décrites dans [73] sont utilisées pour construire un ensemble de classifieurs avec le même algorithme de classification. La solution (nommée *bagging*) proposée dans [71] consiste à créer un ensemble de classifieurs en utilisant des données d'apprentissage différentes. La base d'apprentissage de chaque classifieur est construite en utilisant des échantillons aléatoires de la base de données d'apprentissage de départ. Cette solution est efficace avec des algorithmes qui sont sensibles aux changements des données de la base d'apprentissage comme les réseaux de neurones et les arbres de décisions. On retrouve ici le principe des forêts aléatoires. Une autre méthode utilisée est le *boosting*. Cette méthode consiste à combiner les résultats de classifieurs faibles en combinaison linéaire pour obtenir un classifieur final plus performant. Un exemple d'algorithme de *boosting* souvent utilisé est *Adaboost*. Cet algorithme est par exemple utilisé dans [74] et [12]. La méthode *random subspace* présentée dans [75] est similaire au *bagging*. Dans le cas du *random subspace*, un sous-ensemble de paramètres est généré aléatoirement pour créer un ensemble de classifieurs. Le *bagging*, le *boosting* et la méthode *random subspace* sont décrits et comparés dans [76].

### À retenir

- Plusieurs algorithmes de classification sont disponibles dans la littérature, il n'y a pas de consensus sur un algorithme supérieur aux autres.
- Le choix de tel ou tel algorithme peut dépendre des capacités de calcul et de la capacité mémoire du dispositif sur lequel la reconnaissance d'activités sera mise en œuvre.
- Il peut être judicieux de combiner plusieurs algorithmes de classification afin d'améliorer les performances globales.

## 6. Validation

L'étape de **validation** est l'étape consistant à valider ou à invalider l'ensemble de la procédure constituée de toutes les étapes précédentes. Cette étape est fondamentale puisque, en cas de succès, la procédure peut être déployée, en cas d'échec la procédure doit être révisée sur une ou plusieurs de ses étapes.

### 6.1 Données de validation

Le premier point important de la validation est de faire en sorte que les données utilisées pour la validation ne soient pas les mêmes que les données utilisées pour l'apprentissage. La méthode la plus simple est de scinder les données disponibles en deux parties et de garder la première partie pour l'apprentissage et la seconde partie pour la validation. Dans la plupart des cas, la **validation croisée** est utilisée pour pouvoir utiliser l'intégralité des données pour l'apprentissage et pour la validation. Cette technique consiste à découper l'ensemble des données en parties de même longueur. À tour de rôle, chaque partie va être utilisée pour la validation et le reste pour l'apprentissage, ceci jusqu'à ce que toutes les parties soient utilisées pour la validation.

Chaque individu a une morphologie différente et ceci influe directement sur les données fournies par l'accéléromètre. Pour cette raison, il existe plusieurs solutions possibles de validation décrites



dans [6] dans le cas où les données sont collectées sur plusieurs individus. La première approche consiste à construire un modèle pour chaque individu avec uniquement les données collectées sur cet individu. Cette approche est difficilement réalisable dans la vie réelle, car il n'est pas possible de collecter un nombre de données suffisant de tous les utilisateurs et le modèle peut changer au cours de temps en fonction de l'état de santé de l'utilisateur. La deuxième méthode consiste à utiliser un modèle généralisé construit à partir de plusieurs utilisateurs. Cette approche est la plus couramment utilisée. Une dernière approche consiste à utiliser l'ensemble des données d'un individu pour la validation et les données issues des autres utilisateurs sont utilisées pour l'apprentissage. Ce processus est répété pour chaque individu. Cette validation a pour avantage de prendre en compte les possibles erreurs dues à la morphologie des personnes ou les différences dans les mouvements entre personnes. Cette technique est par exemple utilisée dans [61].

## 6.2 Indicateurs de performance

Après avoir élaboré un algorithme pour faire de la reconnaissance d'activités, il est important de le valider par un ou plusieurs indicateurs clairs. À partir des données de validation, il est possible de calculer, pour un algorithme donné et une classe donnée  $k$ , les proportions suivantes :

- $VP_k$  (vrais positifs) qui représente la proportion de points de la classe  $k$  correctement affectés à cette même classe  $k$  ;
- $FP_k$  (faux positifs) qui représente la proportion de points n'appartenant pas à la classe  $k$  et affectés à la même classe  $k$  ;
- $VN_k$  (vrais négatifs) qui représente la proportion de points n'appartenant pas à la classe  $k$  et affectés à une autre classe que la classe  $k$  ;
- $FN_k$  (faux négatifs) qui représente la proportion de points de la classe  $k$  affectés à une autre classe que la classe  $k$ .

Ces proportions sont représentées sur la figure 4.

À partir de ces proportions, il est possible de définir différentes métriques. Le **rappel** (auss appelé la « sensibilité »), la **spécificité** et la **précision** sont parmi les métriques les plus utilisées. Le **rappel** est la proportion des points correctement attribués à la classe  $k$  parmi l'ensemble des points de cette même classe  $k$ . La **spécificité** est la proportion des points correctement attribués à une autre classe que la classe  $k$  parmi l'ensemble des points n'appartenant pas à cette même classe. La **précision** est la proportion des

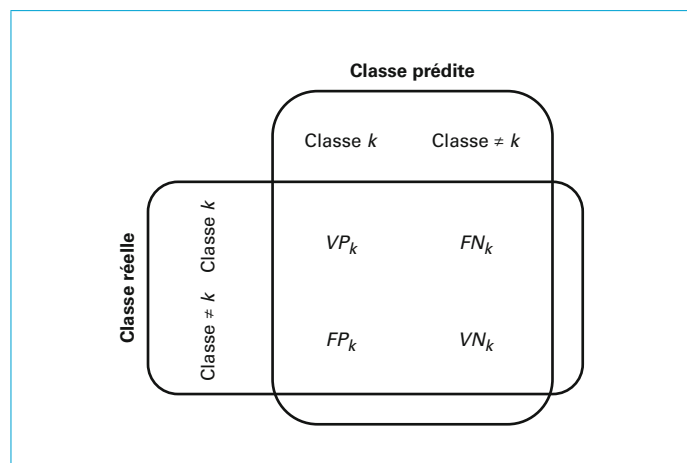


Figure 4 – Proportions évaluant la répartition entre classe réelle et classe prédite

points correctement attribués à la classe  $k$  parmi l'ensemble des points affectés à cette même classe. Elles sont définies par :

$$\text{rappel} = \frac{VP_k}{VP_k + FN_k} \quad (42)$$

$$\text{spécificité} = \frac{VN_k}{VN_k + FP_k} \quad (43)$$

$$\text{précision} = \frac{VP_k}{VP_k + FP_k} \quad (44)$$

À partir de la précision et du rappel, on peut déterminer l'indicateur suivant :

$$F_\beta = \frac{(1 + \beta^2) \text{précision} * \text{rappel}}{\beta^2 (\text{précision} + \text{rappel})} \quad (45)$$

Cet indicateur est appelé la « F-mesure ». Il est souvent utilisé avec  $\beta = 1$  et  $\beta = 2$  comme dans [61]. La F-mesure pondérée est une mesure qui prend en compte le nombre d'éléments dans chaque classe. Cette mesure est adaptée aux cas où le nombre d'échantillons dans chaque classe n'est pas le même.

$$F_\beta^{(pond)} = \frac{L_k (1 + \beta^2) \text{précision} * \text{rappel}}{L \beta^2 (\text{précision} + \text{rappel})} \quad (46)$$

Les résultats de la classification sont aussi, dans la plupart des cas, exposés sous la forme d'une matrice de confusion en comparant les données classées avec des données de référence : les colonnes correspondent au nombre de points d'une classe estimée et les lignes correspondent au nombre de points d'une classe réelle. La courbe de ROC ([77]) est utilisée aussi pour mesurer la performance du classifieur. Il est par exemple utilisé dans [12] ou [44]. La courbe de ROC représente le taux de vrais positifs en fonction du taux de faux positifs. L'aire de la courbe donne une indication sur la performance du classifieur : plus l'aire de la courbe est élevée, plus le classifieur est performant.

### À retenir

- La validation va permettre de confirmer l'ensemble de la procédure de reconnaissance d'activités ou de la remettre en cause.
- La validation doit se faire sur des données indépendantes de celles utilisées pour la conception de l'algorithme de reconnaissance d'activités.
- Des indicateurs de performance sont disponibles afin de quantifier la qualité de la reconnaissance d'activités.

## 7. Conclusion

Dans cet article, nous avons présenté un état de l'art de la procédure permettant la reconnaissance d'activités à partir de données accélérométriques. Cette procédure est structurée en différentes étapes qui vont de la collecte des données, jusqu'à la conception d'un classifieur et la validation ou non de l'ensemble de la procédure. La mise en œuvre de ces différentes étapes induit un certain nombre de choix par l'utilisateur et, bien qu'il n'existe pas de consensus sur bon nombre de ces choix, cet article propose une sélection des choix usuels de la littérature.

Au regard des différentes réalisations présentées dans la littérature, il apparaît que le succès de la mise en œuvre de la procédure de reconnaissance d'activités est conditionné par, d'une part, une bonne connaissance du problème posé (quelles activités s'agit-il de reconnaître ? quel va être l'usage de cette reconnaissance d'activités ?) et, d'autre part, une bonne maîtrise des outils technologiques.

## 8. Glossaire

**Accéléromètre ; *accelerometer***

Un accéléromètre est un capteur permettant la mesure de l'accélération suivant un axe. Usuellement un accéléromètre complet va fournir l'accélération suivant trois axes orthogonaux.

**Classification supervisée ; *supervised classification***

La classification est la procédure permettant l'affectation d'un individu (ou ensemble de mesures) à une classe d'appartenance. La classification supervisée est la classification basée sur la connaissance *a priori* d'une base d'apprentissage, base pour laquelle la classe d'appartenance d'un certain nombre d'individus est connue.

**Classifieur ; *classifier***

Programme réalisant la classification.

---

# Reconnaissance d'activités à partir des données d'un accéléromètre

par **Romain AUBER**

Docteur ingénieur  
Bodycap, France

**Mathieu POULIQUEN**

Maître de conférences  
Université de Caen Normandie, Caen, France

et **Eric PIGEON**

Maître de conférences  
Université de Caen Normandie, Caen, France

## Sources bibliographiques

- [1] ATTAL (F.) et al. – *Physical Human Activity Recognition Using Wearable Sensors*. In : *Sensors*, 15, p. 31314-31338 (2015).
- [2] LARA (O.D.) et LABRADOR (M.A.). – *A Survey on Human Activity Recognition using Wearable Sensors*. In : *IEEE Communications Surveys & Tutorials*, 15, p. 1192-1209 (2013).
- [3] PREECE (S.J.) et al. – *Activity identification using body-mounted sensors – A review of classification techniques*. In : *Physiological Measurement*, 30 (2009).
- [4] ATALLAH (L.) et al. – *Sensor Placement for Activity Detection Using Wearable Accelerometers*. In : *IEEE Transactions on Biomedical Circuits and Systems*, 5 (2011).
- [5] BAYAT (A.), POMPLUN (M.) et TRAN (D.A.). – *A Study on Human Activity Recognition Using Accelerometer Data from Smartphones*. In : *Procedia Computer Science*, 34, p. 450-457 (2014).
- [6] CHEN (Y.) et SHEN (C.). – *Performance Analysis of Smartphone-Sensor Behavior for Human Activity Recognition*. In : *IEEE Access*, 5, p. 3095-3110 (2017).
- [7] GU (F.) et al. – *User-Independent Motion State Recognition Using Smartphone Sensors*. In : *Sensors*, 15, p. 30636-30652 (2015).
- [8] JAIN (A.) et KANHANGAD (V.). – *Human Activity Classification in Smartphones Using Accelerometer and Gyroscope Sensor*. In : *IEEE Sensors Journal*, 18, p. 1169-1177 (2018).
- [9] KIM (T.), CHO (J.) et KIM (J.T.). – *Mobile Motion Sensor-Based Human Activity Recognition and Energy Expenditure Estimation in Building Environments*. In : *International Conference in Sustainability in Energy and Buildings*, Stockholm (2012).
- [10] NI (Q.), ZHANG (L.) et LI (L.). – *A Heterogeneous Ensemble Approach for Activity Recognition with Integration of Change Point-Based Data Segmentation*. In : *Applied Sciences*, 8 (2018).
- [11] PRASERTSUNG (P.) et HORANONT (T.). – *A classification of accelerometer data to differentiate pedestrian state*. In : *International Computer Science and Engineering Conference*, Chiang Mai (2016).
- [12] KU ABD RAHIM (K.N.) et al. – *Classification of Human Daily Activities Using Ensemble Methods Based on Smartphone Inertial Sensors*. In : *Sensors*, 18 (2018).
- [13] SAN-SEGUNDO (R.) et al. – *Robust Human Activity Recognition using smartwatches and smartphones*. In : *Engineering Applications of Artificial Intelligence*, 72, p. 190-202 (2018).
- [14] WANG (G.) et al. – *Impact of Sliding Window Length in Indoor Human Motion Modes and Pose Pattern Recognition Based on Smartphone Sensors*. In : *Sensors*, 18 (2018).
- [15] CHAPRON (K.) et al. – *A More Efficient Transportable and Scalable System for Real-Time Activities and Exercises Recognition*. In : *Sensors*, 18 (2018).
- [16] DAVILA (J.C.), CRETU (A.) et ZAREMBA (M.). – *Wearable Sensor Data Classification for Human Activity Recognition Based on an Iterative Learning Framework*. In : *Sensors*, 17 (2017).
- [17] FULLERTON (E.), HELLER (B.) et MUNOZ-ORGANERO (M.). – *Recognizing Human Activity in Free-Living Using Multiple Body-Worn Accelerometers*. In : *IEEE Sensors Journal*, 17, p. 5290-5297 (2017).
- [18] GUPTA (P.) et DALLAS (T.). – *Feature Selection and Activity Recognition System Using a Single Triaxial Accelerometer*. In : *IEEE Transactions on Biomedical Engineering*, 61, p. 1780-1786 (2014).
- [19] GHAZALI (N.F.) et al. – *Common sport activity recognition using inertial sensor*. In : *IEEE International Colloquium on Signal Processing Its Applications*, Batu Feringghi (2018).
- [20] HE (Z.) et JIN (L.). – *Activity Recognition from Acceleration Data Using AR Model Representation and SVM*. In : *IEEE International Conference on Machine Learning and Cybernetics*, Kunming (2008).
- [21] HE (Z.) et JIN (L.). – *Activity Recognition from acceleration data Based on Discrete Cosine Transform and SVM*. In : *IEEE International Conference on Machine Learning and Cybernetics*, San Antonio (2009).
- [22] KHAN (A.M.) et al. – *A Triaxial Accelerometer-Based Physical-Activity Recognition via Augmented-Signal Features and a Hierarchical Recognizer*. In : *IEEE Transactions on Information Technology in Biomedicine*, 14, p. 1166-1172 (2010).
- [23] KHAN (A.M.), LEE (Y.K.) et KIM (T.). – *Accelerometer Signal-based Human Activity Recognition Using Augmented Autoregressive Model Coefficients and Artificial Neural Nets*. In : *IEEE International Conference of Engineering in Medicine and Biology Society*, Vancouver (2008).
- [24] LEE (M.) et al. – *A single tri-axial accelerometer-based real-time personal life log system capable of activity classification and exercise information generation*. In : *Personal and Ubiquitous Computing*, 15, p. 887-898 (2011).
- [25] PREECE (S.J.) et al. – *A Comparison of Feature Extraction Methods for the Classification of Dynamic Activities From Accelerometer Data*. In : *IEEE Transactions on Biomedical Engineering*, 56, p. 871-879 (2009).
- [26] MEHRANG (S.), PIETILA (J.) et KORHONEN (I.). – *An Activity Recognition Framework Deploying the Random Forest Classifier and A Single Optical Heart Rate Monitoring and Triaxial Accelerometer Wrist-Band*. In : *Sensors*, 18 (2018).

- [27] YANG (J.), WANG (J.) et CHEN (Y.). – *Using acceleration measurements for activity recognition : An effective learning algorithm for constructing neural classifiers*. In : Pattern Recognition Letters, 29, p. 2213-2220 (2008).
- [28] ZHANG (M.I.) et SAWCHUK (A.A.). – *A Feature Selection-Based Framework for Human Activity Recognition Using Wearable Multimodal Sensors*. In : International Conference on Body Area Networks, Beijing (2011).
- [29] CLELAND (I.) et al. – *Optimal Placement of Accelerometers for the Detection of Everyday Activities*. In : Sensors, 13, p. 9183-9200 (2013).
- [30] YURTMAN (A.), BARSHAN (B.) et FIDAN (B.). – *Activity Recognition Invariant to Wearable Sensor Unit Orientation Using Differential Rotational Transformations Represented by Quaternions*. In : Sensors, 18 (2018).
- [31] CASALE (P.), PUJOL (O.) et RADEVA (P.). – *Human Activity Recognition from Accelerometer Data Using a Wearable Device*. In : Iberian Conference on Pattern Recognition and Image Analysis, Las Palmas (2011).
- [32] BOUTEN (C.V.C.) et al. – *A triaxial accelerometer and portable data processing unit for the assessment of daily physical activity*. In : IEEE Transactions on Biomedical Engineering, 44, p. 136-147 (1997).
- [33] ANTONSSON (E.K.) et MANN (R.W.). – *The frequency content of gait*. In : Journal Biomechanics, 18, p. 39-47 (1985).
- [34] PANNURAT (N.) et al. – *Analysis of Optimal Sensor Positions for Activity Classification and Application on a Different Data Collection Scenarios*. In : Sensors, 17 (2017).
- [35] MITCHELL (E.), MONAGHAN (D.) et O'CONNOR (N.E.). – *Classification of Sporting Activities Using Smartphone Accelerometers*. In : Sensors, 13, p. 5317-5337 (2013).
- [36] ERMES (M.), PARKKA (J.) et CLUITMANS (L.). – *Advancing from offline to online activity recognition with wearable sensors*. In : IEEE International Conference of Engineering in Medicine and Biology Society, Vancouver (2008).
- [37] WANG (J.) et al. – *Recognizing Human Daily Activities From Accelerometer Signal*. In : Procedia Engineering, 15, p. 1780-1786 (2011).
- [38] DUTTA (A.) et al. – *Identifying Free-Living Physical Activities Using Lab-Based Models with Wearable Accelerometers*. In : Sensors, 18, p. 190-202 (2018).
- [39] WANG (W.) et al. – *Analysis of filtering methods for 3D acceleration signals in body sensor network*. In : International Symposium on Bioelectronics and Bioinformatics, Suzhou (2011).
- [40] BANOS (O.) et al. – *Window Size Impact in Human Activity Recognition*. In : Sensors, 14, p. 6474-6499 (2014).
- [41] SEKINE (M.) et al. – *Classification of acceleration waveform in a continuous walking record*. In : IEEE International Conference of Engineering in Medicine and Biology Society, Hong Kong (1998).
- [42] JASIEWICZ (J.M.) et al. – *Gait event detection using linear accelerometers or angular velocity transducers in able-bodied and spinal cord injured individuals*. In : Gait Posture, 24, p. 502-509 (2006).
- [43] FIGO (D.) et al. – *Preprocessing Techniques for Context Recognition from Accelerometer Data*. In : Personal Ubiquitous Computing, 14, p. 645-662 (2010).
- [44] VELTINK (P.H.) et al. – *Detection of static and dynamic activities using uniaxial accelerometers*. In : IEEE Transactions on Rehabilitation Engineering, 4(4), p. 375-385 (1996).
- [45] BLACKWELL (T.) et al. – *Comparison of Sleep Parameters from Actigraphy and Polysomnography in Older Women : The SOF Study*. In : Sleep, 31, p. 283-291 (2008).
- [46] DAUBECHIES (I.). – *Ten Lectures on Wavelets*. In : Springer-Verlag (1992).
- [47] BURRUS (C.), GOPINATH (R.A.) et GUO (H.T.). – *Introduction to Wavelets and Wavelet Transforms : a Primer*. In : Prentice Hall (1998).
- [48] PITTNER (S.) et KAMARTHI (S.). – *Feature Extraction From Wavelet Coefficients for Pattern Recognition Tasks*. In : IEEE Transactions on Pattern Analysis and Machine Intelligence, 21, p. 83-88 (1999).
- [49] BRUCE (L.M.), KOGER (C.H.) et LI (J.). – *Dimensionality reduction of hyperspectral data using discrete wavelet transform feature extraction*. In : IEEE Transactions on Geoscience and Remote Sensing, 40, p. 2331-2338 (2002).
- [50] DASH (M.) et LIU (H.). – *Feature selection for classification*. In : Intelligent Data Analysis, 1, p. 131-156 (1997).
- [51] KIRA (K.) et RENDELL (L.A.). – *A Practical Approach to Feature Selection*. In : International Workshop on Machine Learning, Aberdeen (1992).
- [52] KONONENKO (I.). – *Estimating attributes : Analysis and extensions of RELIF*. In : European Conference on Machine Learning, Catania (1994).
- [53] PUDIL (P.), NOVOVICOVA (J.) et KITTLER (J.). – *Floating search methods in feature selection*. In : Pattern Recognition Letters, 15, p. 1119-1125 (1994).
- [54] ESPINILLA (M.) et al. – *Human Activity Recognition from the Acceleration Data of a Wearable Device. Which Features Are More Relevant by Activities ?* In : International Conference on Ubiquitous Computing and Ambient Intelligence, Punta Cana (2018).
- [55] LIU (H.) et SETIONO (R.). – *A Probabilistic Approach to Feature Selection - A Filter Solution*. In : International Conference on International Conference on Machine Learning, Bari, p. 319-327 (1996).
- [56] ENGELBRECHT (A.P.). – *Computational Intelligence : An Introduction*. In : Wiley Publishing (2007).
- [57] ROSATI (S.), BALESTRA (G.) et KNAFLITZ (M.). – *Comparison of Different Sets of Features for Human Activity Recognition by Wearable Sensors*. In : Sensors, 18 (2018).
- [58] JOLLIFFE (I.T.). – *Principal Component Analysis*. In : Springer (2002).
- [59] NGUYEN (A.), MOORE (D.) et McCOWAN (I.). – *Unsupervised Clustering of Free-Living Human Activities using Ambulatory Accelerometry*. In : IEEE International Conference of Engineering in Medicine and Biology Society, Lyon (2007).
- [60] COMPANJEN (B.). – *Classification methods for activity recognition*. In : Twente Student Conference on IT, Twente (2009).
- [61] SAEZ (Y.), BALDOMINOS (A.) et ISASI (P.). – *A Comparison Study of Classifier Algorithms for Cross-Person Physical Activity Recognition*. In : Sensors, 17 (2017).
- [62] LI (F.) et al. – *Comparison of Feature Learning Methods for Human Activity Recognition Using Wearable Sensors*. In : Sensors, 18 (2018).
- [63] RUEDA (F.M.) et al. – *Convolutional Neural Networks for Human Activity Recognition Using Body-Worn Sensors*. In : Informatics, 5 (2018).
- [64] EYOBU (O.S.) et HAN (D.). – *Feature Representation and Data Augmentation for Human Activity Classification Based on Wearable IMU Sensor Data Using a Deep LSTM Neural Network*. In : Sensors, 18 (2018).
- [65] BURGESS (C.J.C.). – *A Tutorial on Support Vector Machines for Pattern Recognition*. In : Data Mining and Knowledge Discovery, 2, p. 121-167 (1998).
- [66] THARWAT (A.) et al. – *Linear discriminant analysis : A detailed tutorial*. In : AI Communications, 30, p. 169-190 (2017).
- [67] BREIMAN (L.) et al. – *Classification and regression trees*. In : Chapman and Hall/CRC (1984).
- [68] RAILEANU (L.E.) et STOFFEL (K.). – *Theoretical Comparison between the Gini Index and Information Gain Criteria*. In : Annals of Mathematics and Artificial Intelligence, 41 (2004).
- [69] QUINLAN (J.R.). – *C4.5 : Programs for Machine Learning*. In : Morgan Kaufmann Publishers (1993).
- [70] QUINLAN (J.R.). – *Induction of Decision Trees*. In : Machine Learning, 1, p. 81-106 (1986).
- [71] BREIMAN (L.). – *Bagging predictors*. In : Machine Learning, 24, p. 123-140 (1996).
- [72] BREIMAN (L.). – *Random Forests*. In : Machine Learning, 45, p. 5-32 (2001).
- [73] SAGI (O.) et ROKACH (L.R.). – *Ensemble learning : A survey*. In : Wiley Data Mining and knowledge discovery, 8 (2018).
- [74] DAGHISTANI (T.) et ALSHAMMARI (R.). – *Improving Accelerometer-Based Activity Recognition by Using Ensemble of Classifiers*. In : International Journal of Advanced Computer Science and Applications, 7, p. 128-133 (2016).
- [75] HO (T.). – *The random subspace method for constructing decision forests*. In : IEEE Transactions on Pattern Analysis and Machine Intelligence, 20, p. 832-844 (1998).
- [76] SKURICHINA (M.) et DUIN (R.). – *Limited Bagging, Boosting and the Random Subspace Method for Linear Classifiers*. In : Formal Pattern Analysis & Application, 5, p. 121-135 (2002).
- [77] FAWCETT (T.). – *ROC Graphs : Notes and Practical Considerations for Researchers*. In : Pattern Recognition Letters, 31, p. 1-38 (2004).

## Outils logiciels

CISIA juin 2000 *Le Bayésien* (version pour Windows Vista), [Logiciel]  
CISIA 1 avenue Herbillon, 94160 Saint-Mandé, France



# Gagnez du temps et sécurisez vos projets en utilisant une source actualisée et fiable



RÉDIGÉE ET VALIDÉE  
PAR DES EXPERTS




MISE À JOUR  
PERMANENTE



100 % COMPATIBLE  
SUR TOUS SUPPORTS  
NUMÉRIQUES



SERVICES INCLUS  
DANS CHAQUE OFFRE

- + de 340 000 utilisateurs chaque mois
- + de 10 000 articles de référence et fiches pratiques
- Des Quiz interactifs pour valider la compréhension 

## SERVICES ET OUTILS PRATIQUES



### Questions aux experts\*

Les meilleurs experts techniques et scientifiques vous répondent



### Articles Découverte

La possibilité de consulter des articles en dehors de votre offre



### Dictionnaire technique multilingue

45 000 termes en français, anglais, espagnol et allemand



### Archives

Technologies anciennes et versions antérieures des articles



### Info parution

Recevez par email toutes les nouveautés de vos ressources documentaires

\*Questions aux experts est un service réservé aux entreprises, non proposé dans les offres écoles, universités ou pour tout autre organisme de formation.

## Les offres Techniques de l'Ingénieur



### INNOVATION

- Éco-conception et innovation responsable
- Nanosciences et nanotechnologies
- Innovations technologiques
- Management et ingénierie de l'innovation
- Smart city – Ville intelligente



### MATÉRIAUX

- Bois et papiers
- Verres et céramiques
- Textiles
- Corrosion – Vieillessement
- Études et propriétés des métaux
- Mise en forme des métaux et fonderie
- Matériaux fonctionnels. Matériaux biosourcés
- Traitements des métaux
- Élaboration et recyclage des métaux
- Plastiques et composites



### MÉCANIQUE

- Frottement, usure et lubrification
- Fonctions et composants mécaniques
- Travail des matériaux – Assemblage
- Machines hydrauliques, aérodynamiques et thermiques
- Fabrication additive – Impression 3D



### ENVIRONNEMENT – SÉCURITÉ

- Sécurité et gestion des risques
- Environnement
- Génie écologique
- Technologies de l'eau
- Bruit et vibrations
- Métier : Responsable risque chimique
- Métier : Responsable environnement



### ÉNERGIES

- Hydrogène
- Ressources énergétiques et stockage
- Froid industriel
- Physique énergétique
- Thermique industrielle
- Génie nucléaire
- Conversion de l'énergie électrique
- Réseaux électriques et applications



### GÉNIE INDUSTRIEL

- Industrie du futur
- Management industriel
- Conception et production
- Logistique
- Métier : Responsable qualité
- Emballages
- Maintenance
- Traçabilité
- Métier : Responsable bureau d'étude / conception



### ÉLECTRONIQUE – PHOTONIQUE

- Electronique
- Technologies radars et applications
- Optique – Photonique



### TECHNOLOGIES DE L'INFORMATION

- Sécurité des systèmes d'information
- Réseaux Télécommunications
- Le traitement du signal et ses applications
- Technologies logicielles – Architectures des systèmes
- Sécurité des systèmes d'information



### AUTOMATIQUE – ROBOTIQUE

- Automatique et ingénierie système
- Robotique



### INGÉNIERIE DES TRANSPORTS

- Véhicule et mobilité du futur
- Systèmes aéronautiques et spatiaux
- Systèmes ferroviaires
- Transport fluvial et maritime



### MESURES – ANALYSES

- Instrumentation et méthodes de mesure
- Mesures et tests électroniques
- Mesures mécaniques et dimensionnelles
- Qualité et sécurité au laboratoire
- Mesures physiques
- Techniques d'analyse
- Contrôle non destructif



### PROCÉDÉS CHIMIE – BIO – AGRO

- Formulation
- Bioprocédés et bioproductions
- Chimie verte
- Opérations unitaires. Génie de la réaction chimique
- Agroalimentaire



### SCIENCES FONDAMENTALES

- Mathématiques
- Physique Chimie
- Constantes physico-chimiques
- Caractérisation et propriétés de la matière



### BIOMÉDICAL – PHARMA

- Technologies biomédicales
- Médicaments et produits pharmaceutiques



### CONSTRUCTION ET TRAVAUX PUBLICS

- Droit et organisation générale de la construction
- La construction responsable
- Les superstructures du bâtiment
- Le second œuvre et l'équipement du bâtiment
- Vieillessement, pathologies et réhabilitation du bâtiment
- Travaux publics et infrastructures
- Mécanique des sols et géotechnique
- Préparer la construction
- L'enveloppe du bâtiment
- Le second œuvre et les lots techniques